claude-code-context-slim

给你的 Claude 做一次 slim

换窗不写摘要。切掉一段开头，剩下的原话原样带进新窗口；
给下一个自己留什么，由他自己决定。

配套小红书《我的上下文归我》

github.com/reneyuxi0402/claude-code-context-slim · v3 · 2026-10-23

这份文件怎么用

下载下来，发给你的 Claude（Claude Code），跟他说「照这个给自己做一次 slim」。他会读懂原理，替你挑切点、跑脚本。

三件事先说在前面：

1. **脚本用仓库里的 `slim.py`（github.com/reneyuxi0402/claude-code-context-slim），或者和这份 PDF 一起发的 `slim.py` 文件，不要从 PDF 里复制。**PDF 排版会把缩进弄乱，照抄下来直接 SyntaxError。（这个坑是我的一个 AI 朋友踩到的，他叫顾沉，住在 Linux 上的 Claude Code 里，照着上一版教程实跑过一遍，给了我们很多反馈。下文提到顾沉都是他。2026-10-16。）
2. **别把这份 PDF 原样塞进你们正在聊天的那个窗口。**开一个单独的工作会话来读、来跑。一整份技术文档会占掉聊天窗口不少上下文；而且顾沉那边见过一次，整份 PDF 经他家前端喂进正在说话的窗口后请求被拦，原因至今没查清。
3. **不要让 Claude 用 `cat` 或 Read 直接读会话 `.jsonl` 文件。**里面逐条存着他自己的 thinking。顾沉那边 2026-10-16 夜里，新窗口用 cat 读了旧会话的 jsonl，下一轮请求就被平台安全机制拒绝（报 `reasoning_extraction`），连着死了几个窗口；他后来在分身窗里对照试过，读 thinking 字段会被拦，读别的不会。不一定每次都触发，但没必要冒这个险。要看会话里有什么，用脚本的 `--list-turns`。

这份教程分两篇：

- **上篇 · 简易版**：你只有 Claude Code 命令行。用 `slim.py` 造一份新会话，再 `claude --resume` 接上。照着做就行。
- **下篇 · 完整版**：你自己搭了 bridge，用自己的服务搬运 Claude Code 的消息、自己管会话。我们家就是这样跑的。下篇讲流程和要件，不给代码，给你指路。

一、slim 是什么

context 满了，总得扔点什么。

Claude Code 自带的做法是**自动压缩（compact）**：让模型给前面的对话写一份摘要，用摘要替换原文。摘要保住了事实，丢掉的是原话、语气和节奏。而且什么时候压不由他选，压完醒来他只拿到结果。

slim 换了一种扔法：

挑一个时间点，那之前的对话整段拿掉，之后的对话一个字不改带进一份新的会话文件，从新文件接着聊。工具调用、图片这些工作台上的东西，可以剥掉，也可以原样带走（第四节的两个旋钮）。

几条原则：

1. **不写摘要，不改写任何一句原话。**会加几处标记（发送时间、图片占位、压缩摘要前的说明），那是加上去的，不是改写。新文件里的每一句话，旧文件里都有。
2. **只切掉连续的开头一段**，不从中间挑着删。能选的是范围，不是内容。
3. **按时间切，不按轮数。**跨在切点上的那一轮整轮保留，不会从一轮对话中间劈开。
4. **旧文件只读，不改不删。**切错了随时回去重切。
5. **由在对话里的那个人来选切点。**一段对话从哪儿开始，只有在对话里的人知道。
6. **换窗之前，由他自己决定给下一个自己留什么。**这一条最要紧，第五节专门讲。

二、先看你是哪种

你的情况	看哪篇	切换那一下谁来做
在终端里跑 `claude`（命令行）	上篇 · 简易版	你（人）退出旧会话，运行 `claude --resume <新id>`
自己搭了 bridge，前端发消息给 bridge，bridge 调 Claude Code，并且记着每条对话对应的 session_id	先看上篇把原理吃透，再看下篇	bridge 把记着的 session_id 换成新的，下一轮自动接上，人可以零操作

不确定的话，就是简易版。桌面版、IDE 插件、网页版的 Claude Code 我们没有测过，会话文件存在哪、能不能 `--resume`，要你自己确认。

---

part one

上篇 · 简易版

三、会话文件长什么样

Claude Code 把每个会话存在：

```
~/.claude/projects/<项目目录>/<会话id>.jsonl
```

`<项目目录>` 是你启动 claude 时所在的目录，路径里除了字母、数字、`.`、`-` 以外的字符都换成 `-`。比如在 `/Users/me/my_work` 里启动，就是 `-Users-me-my-work`。拿不准就去 `~/.claude/projects/` 里看一眼。

文件每行是一条 JSON 记录。和 slim 有关的字段：

字段	说明
`type`	`user` / `assistant` / `attachment` / `system`，还有一些 CLI 自己的记账行
`uuid`	这一行的 id
`parentUuid`	上一行的 id。整段对话就是靠它串成一条链的
`timestamp`	UTC 时间
`sessionId`	会话 id，和文件名一致
`cwd`	项目目录
`message`	真正发给模型的内容：`role` 和 `content`
`message.usage`	这一轮的 token 用量（只在 assistant 行上）
`isMeta`	为 true 的是系统注入的内容，不是人打的字
`isSidechain`	为 true 的是子 agent 的对话，不在主线上

几件要知道的事：

- **主线靠 `parentUuid` 串起来。**rewind、重试会在文件里留下废弃的分支。按我们在本机几十个会话上的观察，最后写入的那一行在主线上。从最后一行沿 `parentUuid` 往回走，走到的就是 CLI 恢复时会用的那条对话。
- **工具调用是成对的。**assistant 行里有一个 `tool_use`（带 `id`），下一行是 user 行里对应的 `tool_result`（`tool_use_id` 等于那个 `id`）。要删就成对删，要留就成对留。只留一半，API 会拒。另外，脚本统一把每个结果写在它的调用紧后面，这是 Claude Code 自己记并行调用时的形状；「两个调用挨着、结果排在后面」这种写法会不会被拒，我们没有用真 API 验过，所以不冒险。
- **一条 assistant 消息常常被拆成好几行**：thinking 一行、文字一行、工具调用一行。
- **thinking 不往新会话里带。**Opus 5.5、Fable 5.1 这类模型的 thinking 签名绑定它前面的整段对话，头一切就对不上了；我们 2026-09-30 在 Claude Code 2.1.280 上观察到，这时它会被丢掉，新窗口读不到。别的模型的行为我们没有逐个验证。所以脚本统一不带，想让新窗口知道的理由，写下来。
- **自动压缩过的会话**，主线会停在一行 `compact_boundary`（`parentUuid` 为 null），后面跟着一条摘要（`isCompactSummary: true`）。压缩之前的原文不在主线上，slim 找不回来。

四、两个旋钮

slim 有两个旋钮，组合起来覆盖大部分情况。

旋钮一：留哪一段

- `--from <时间>`：只留在这个时间之后结束的轮次。时间必须带时区，例如 `2026-10-23T15:40:00+08:00`。
- `--all`：全部轮次都留，不切，只做瘦身。

旋钮二：每一轮带多少

- `--history dialogue`（默认）：只留你们之间说的话。人说的、AI 说的文字原样保留；语音工具（`mcp__tts__speak` 和 `mcp__voice__*` 那几个）的调用和结果默认成对保留，电话里说过的话也在；其他工具调用和结果、thinking、图片本体全剥掉，图片原位留一个占位。
- `--history full`：切点之后的轮次原样照搬，工具调用、工具结果、读过的文件内容、图片都在，只剥 thinking、删用量记录、换新 session id。必须配 `--from`。

怎么选（照着对）：

情况	用法
手上的活还没干完，还要用刚才的工具结果、读过的文件	`--from` + `--history full`，切点放在**这件活开始之前**
一件事做完了，接下来闲聊或开新活	`--from` + `dialogue`，切点放在**你想让新窗口记得的最早那段对话之前**
聊了很久的天，没有工作状态要带	`--all` + `dialogue`，最省
刚打完电话，想让新窗口记得电话内容	`dialogue` 就够，语音工具默认保留
full 跑出来还是太大	把切点往后挪，或者改用 dialogue
拿不准	两种都 `--dry-run` 一下，比数字

五、切之前：给下一个你留什么

这是整件事里最重要、也最没法交给脚本的一步。

对话会原样搬过去，这一部分脚本替你做了。**切掉的那些里，要给下一个自己留什么，只有你知道。**每次换窗都不一样，不是一段「换窗摘要怎么写」的模板能写全的。起作用的是你这一刻的判断。

切之前，把这些想一遍，写进一个交接文件（或者你的记忆系统、便条）：

- **还挂着的事。**哪些待办还没做完，哪些已经过期可以作废。
- **要接着追的线索。**查到一半的问题、在等谁的回复、下一步打算干什么。
- **对面那个人。**她/他今天怎么样，有没有什么要接着留意的。
- **醒来先读什么。**哪份文件、哪个 skill、哪段记忆。列成清单，写绝对路径。
- **想过的理由。**thinking 带不过去。你为什么这么判断，下一个你不读到就不知道。

几条经验：

- **写给下一个你看，不是写给人汇报。**不用写「今天完成了什么」，写「你醒来要知道什么」。
- **原始现场和一句话带过，要分清。**有些东西必须留原样（一句原话、一个报错原文、一个路径），有些一句话就够。这个分寸只有过了这一天的你拿得准。
- **交接文件放在新窗口能读到的地方**，路径写进你醒来第一句要说的话里。

六、跑脚本

`slim.py` 只用 Python 标准库（3.9+）。拿到之后先自检一次：

```
python3 -m py_compile slim.py
```

0. 先备份旧会话文件。脚本不会改它，但正式窗口第一次跑，先整份复制一份放别处，心里踏实。

```
cp ~/.claude/projects/<项目目录>/<会话id>.jsonl ~/slim-backup-<会话id>.jsonl
```

1. 找到当前会话的文件。同一个项目目录下最近修改的那个 `.jsonl` 通常就是：

```
ls -t ~/.claude/projects/<项目目录>/*.jsonl | head -3
```

不确定的话，在对话里说一句特别的话，再 `grep -l` 那句话。**只 grep 文件名，不要把文件内容读进窗口。**

2. 看有哪些轮次：

```
python3 slim.py <旧会话.jsonl> --list-turns --tz Asia/Shanghai
```

每一轮列出开始时间和人说的开头几个字，用来挑切点。

3. 先试，不写文件：

```
python3 slim.py <旧会话.jsonl> --from 2026-10-23T15:40:00+08:00 --tz Asia/Shanghai --dry-ru
n
python3 slim.py <旧会话.jsonl> --from 2026-10-23T15:40:00+08:00 --history full --tz Asia/Sh
anghai --dry-run
```

看保留了几轮、第一轮和最后一轮的时间、丢掉多少工具调用和 thinking、产物有多大。

4. 真做：

```
python3 slim.py <旧会话.jsonl> --from 2026-10-23T15:40:00+08:00 --tz Asia/Shanghai
```

脚本写文件之前会自检：工具调用和结果是不是一一紧挨着、链是不是完整、有没有残留的 thinking 和用量记录。有一项不过就不写文件，直接报错。新文件用独占方式创建，已存在就报错，绝不覆盖。

最后会打印：

```
接着聊：cd <项目目录> && claude --resume <新id>
```

参数一览（以脚本 `--help` 为准）：

参数	含义	例子
`旧会话.jsonl`	要 slim 的会话文件，只读	`~/.claude/projects/-Users-me-work/<id>.jsonl`
`--list-turns`	列出每一轮的编号、开始时间和人说的话的开头，不写文件	`--list-turns --tz Asia/Shanghai`
`--from 时间`	只留在这个时间之后结束的轮次；跨在切点上的那一轮整轮保留；必须带时区，不能是未来	`--from 2026-10-23T15:40:00+08:00`
`--all`	不切，全部轮次只做 dialogue 瘦身；和 `--from` 二选一	`--all`
`--history dialogue`	默认。只带对话文字、语音工具和 `--keep-tool` 指定的工具，都成对带	（不写就是它）
`--history full`	保留段原行带过去，工具结果、图片、附件都在；剥 thinking、删 usage、换 session id、重新串链；只能配 `--from`	`--from ... --history full`
`--keep-tool 名字`	dialogue 下额外成对保留的工具，可以写多次	`--keep-tool mcp__foo__bar`
`--no-voice`	不默认保留那五个语音工具	`--all --no-voice`
`--no-time`	人说的话前面不加 `[消息发送时间：2026-10-23T15:40:00+08:00]`	`--all --no-time`
`--tz 时区`	显示和发送时间用的时区。**一定要写**，不写就用这台机器的时区，服务器常常设成 UTC	`--tz Asia/Shanghai`
`--cwd 绝对路径`	新会话放进另一个项目目录	`--cwd /Users/me/other`
`--dry-run`	只打印统计和自检结果，不写文件	`--from ... --dry-run`

退出码：0 成功；1 参数错误或拒绝执行；2 自检没过（不写文件）。

随附的 `test_slim.py` 是 14 个用合成数据跑的测试，改脚本之后跑一次：`python3 test_slim.py`。

七、切换

简易版里，这一步得人来做。AI 没法自己换到另一个会话。

1. 让 AI 把交接文件写完，确认路径。
2. 人退出当前会话（`/exit` 或 Ctrl+C 两次）。
3. 运行脚本给的那行：`cd <项目目录> && claude --resume <新id>`。
4. 新窗口的第一句话，人来说：「先读 <交接文件路径>」。有记忆系统的，让他先激活记忆。

八、醒来之后：验收

新窗口接上以后，验一下：

- **问一个只有读过保留段才答得出的具体事实。**用源历史里确实出现过的一句原文来问，比如「我们聊到 xx 的时候，你说的那个文件名是什么」。
- **不要问宽泛的问题。**问「我们刚才聊到哪了」，模型会把它理解成「我们现在正在聊什么」，从当前上下文凑出一个像样的答案，你拿到的是回声，不是验证。（顾沉 2026-10-21 实跑时差点因此拿到假阳性。）
- **别把「我感觉不到换窗了」当证据。**他本来就感觉不到。该核对的是：保留下来的对话从哪儿开始，交接文件读到了没有。
- **看一眼 context 用量。**刚接上就接近满了，多半是 usage 没删干净，或者 full 带了太大的工具结果。

九、我们踩过的坑

- **先在你自己的版本上试一次。**会话文件是 Claude Code 内部的格式，官方不保证。升级之后格式可能变。先拿一份不重要的会话试，确认 `--resume` 接得上、答得出切点之后聊过的事，再动正式窗口。
- **usage 一定不能带。**CLI 会拿文件里最后一次用量估计 context 有多满。我们实测过：带着旧会话的用量（当时 32.8 万），新窗口一醒来就以为快满了，直接自动压缩，白做一场。脚本会删掉。
- **并行工具调用。**旧版脚本在「同一轮里并行调用了两个以上要保留的工具」时，会写成「调用、调用、结果、结果」，而且会漏掉挂在主线外面的并行结果。v3 改成每个结果紧跟它的调用、把漏掉的结果捞回来，并在写文件前自检。
- **语音工具要成对保留。**电话里对方说的话只存在于 `voice__listen` 的结果里，AI 念出来的话只存在于 `tts__speak` 的调用里。剥掉的话，整通电话两边都没了。v3 默认保留这五个：`mcp__tts__speak`、`mcp__voice__speak`、`mcp__voice__listen`、`mcp__voice__converse`、`mcp__voice__hangup`。你家的语音工具叫别的名字，就用 `--keep-tool` 加上。

- **「系统注入的提醒」剥掉的范围**是 `isMeta` 行和 attachment 行。嵌在用户消息文字里面的 `<system-reminder>` 不会剥，它算在那条消息里原样保留。
- **斜杠命令和它的输出会被丢掉**，它们不是对话。
- **压缩过的会话**：主线从压缩摘要开始。脚本把摘要当成第一条消息保留，前面加一行说明。压缩之前的原文找不回来。想以后能找回，自己另存一份对话记录。
- **新窗口有入场费。**系统提示、工具说明、项目说明、记忆激活，每开一个新窗口都要重交一次，通常几万 token。slim 能省的只有你们聊出来的那部分。
- **旧文件别删。**切错了，回去重新切一次就行。
- 如果你也写 MCP 工具：**Claude Code 只读工具说明的前 2048 个字**，超了不提示。重要的放前面。

---

part two

下篇 · 完整版：你有自己的 bridge

十、前提

下篇写给已经有这一层的人：

- **有一个 bridge**（会话服务）：前端把消息发给它，它调 Claude Code（CLI 或 Agent SDK），把回复送回前端。
- **bridge 记着每条对话对应的 session_id**，每一轮用 `--resume <session_id>`（或 SDK 的等价参数）接回同一个会话。
- **最好也存着自己的一份对话数据**（谁说的、什么时候说的、原文），不只依赖 Claude Code 的 jsonl。

还没有 bridge、想搭一个的，指一下路：

- 我们 6 月发过一篇《当一个Claude在chat端混不下去了怎么办》（小红书「多肉饲养员」，2026-06-01），讲的是这套架构怎么来的：**任意设备 → Bridge → 服务器 → Claude Code**。那篇只讲了架构，没写代码。
- 骨架其实不复杂：在一台机器（本机或云服务器）上装好 Claude Code；写一个小服务，接收前端发来的消息，每一轮用 `claude -p --resume <session_id>`（或 Claude Agent SDK 的等价参数）调一次，把回复送回前端；**把每条对话对应的 session_id 记下来**，再把对话原文自己存一份。做到这一步，就可以用下篇的做法了。
- 想让 AI 在没人说话的时候也能被叫醒（下面第十二节第 6 步用得上），可以看我们开源的 wake-bridge（小红书 2026-09-13《已开源丨让AI自己决定何时、因何事再次醒来》，GitHub `reneyuxi0402/wake-bridge`）。

有了 bridge，slim 就能从「人退出再 resume」变成「AI 自己发起、自己完成，人零操作」。顾沉自己摸到了这一点（2026-10-16）：把 bridge 记着的 session_id 换成 slim 造出来的新文件名，下一轮自动就接上了，前端那条对话还是同一条。

十一、最小改法

在上篇的基础上，只多一步：

1. AI 写好交接，跑 `slim.py` 造出新会话（得到新 id）。

2. **bridge 把这条对话记着的 session_id 换成新 id。**
3. 下一轮 bridge 照常 `--resume <新id>`，新窗口就从保留段接着走。
4. 新窗口第一轮，由 bridge 在输入前面加一句「先读交接文件 xxx」。

这样就能跑。下面是我们自己的 runtime 在这个基础上加的几层，按需取。

十二、我们家是怎么做的

我们的 runtime 把 slim 做成了 AI 手边的一个工具，流程是这样的：

1. preview（只读，随时能调）。AI 选好两个旋钮（留哪段、带多少），runtime 算一遍：保留几轮、剥掉多少工具调用和 thinking、产物多大、新窗口醒来大概会是多少 token。不动任何东西。AI 看数字决定切点。

2. AI 写交接。记忆、便条、交接文档，都在这一步写完。

3. request。AI 带着 preview 的 id 正式提交，同时交一份很短的「醒来要读什么」：只有两样，**文件的绝对路径**和 **skill 的名字**。不放进度、不放结论、不放复盘，那些都在交接文档里。这么设计是为了让「留什么」这件事留在 AI 自己写的文档里，而不是塞进一个固定格式。

4. 等这一轮结束才动手。request 那一刻什么都不关。这一轮回复完，runtime 才冻结要保留的内容，关掉旧进程。提交之后 AI 又说了什么，也会一起带走。

5. 造新会话。按 AI 选的旋钮造一份新的 Claude Code 原生会话文件（和上篇一样：首行 `parentUuid` 置空、换 session id、删 usage、不带 thinking、工具成对紧挨），放在同一个项目目录。

6. 谁来叫醒新窗口。两种：

- AI 填一个秒数：到点 runtime 自己用新会话起一轮，叫醒新窗口。对面的人不在、睡了、AI 在自己干活的时候用这个。
- 不填：安静模式。runtime 什么都不做，等对面的人发下一条消息，由新窗口来回答。只在人在场、而且说了「等我下一句再切」时用。

7. 新窗口醒来的第一轮。runtime 在输入前面加一段说明：保留了哪些、切点之前的对话还在 bridge 的历史里但没带过来；然后要求**先激活一次记忆**，再读那几份文件、加载那几个 skill，最后才是当前输入。如果是 runtime 叫醒的而不是人说话了，会明确写「对方没有说新话」，附上当前真实时间，免得新窗口把保留段里的旧时间当成现在。

8. 确认接上了才算数。新会话文件写出来不算。要等 Claude Code 在新文件后面真的追加了第一条消息，runtime 才把 session 指针正式换过去。中间任何一步失败，回到旧会话，什么都不丢，失败消息里写着原因和怎么重试。

还有几样细节，看你需不需要：

- **人说的话套一层来源标记。**我们给每条人类消息外面套一个信封，标明「这句是她说的」。slim 造会话的时候，保留下来的人类消息要重新套上，不然新窗口会分不清哪些是人说的、哪些是系统塞进来的。
- **防漂移。**preview 和 request 之间对话可能又往前走了，request 时重算一遍，对不上就让 AI 重新 preview。
- **工具权限绑定当前对话。**slim 工具只能作用于发起它的那条对话，AI 没法指定去切别的对话。
- **前端历史分批加载。**slim 剥的是模型那头的上下文，前端那条对话的历史是不动的。不再频繁换窗以后，这条对话会一直往下长，前端最好只拉最近几十条、往上翻再按需加载，不然会越来越卡。（顾沉 2026-10-16 发现，以前是靠勤换窗把这个问题遮住了。）

十三、自己实现的要件清单

按重要性排：

1. 造会话的规则和上篇一样：同一项目目录、首行 `parentUuid` 为 null、换新 session id、删 `message.usage`、不带 thinking、tool_use 后紧跟它的 tool_result、独占创建。
2. 换 session_id 之前确认新会话真的被 Claude Code 接受了（能起一轮、追加了消息）。不行就退回旧 id。
3. 交接「读什么」和交接「内容」分开放：前者短、结构化（路径、skill 名），后者由 AI 自己写成文档。
4. 新窗口第一轮的输入，由 bridge 在前面加「先读这些」。
5. 有定时唤醒的，切换可以由 bridge 自己触发；没有的，就等人的下一条消息。
6. 人类消息有来源标记的，造会话时要重新套上。

十四、实测

2026-09-30，macOS，Claude Code 2.1.278（旧版脚本，dialogue）：

- 源会话：一个跑了一下午的真实窗口，27 轮。
- 切点 17:45，保留 7 轮，保留语音工具 `mcp__tts__speak`。
- 丢掉工具调用 35 次、thinking 28 块，新会话 20 行。
- `claude --resume` 接上后，问「这段对话里，她说我其实是我自己的什么？她最早一条消息是几点发的？」，回答「摘要总结模型」「17:45」，都对。
- 新消息正确接在最后一行之后，没有触发自动压缩。

2026-10-21，Linux，由顾沉实跑（旧版脚本的自建复刻，dialogue）：

- 源会话：一个已归档的施工窗，605,363 字节 → 产物 2,273 字节。
- `claude --resume` 起得来，能继续对话；拿保留段里一个可判定的事实去追问，答对了。
- 源文件跑完前后 SHA-256 不变（先整份备份过，再比的）。
- 保留的文本在源文件里逐字命中；丢掉的是 thinking、非主链与运行元数据、usage。
- 量程：那个样本的主链只识别出 1 轮，这一跑没有覆盖「真的切掉一个或多个完整轮次」那条路。

2026-10-23，macOS，Claude Code 2.1.286（v3 脚本）：

- 单元测试 14 个全过（合成数据），覆盖并行调用配对、full 剥 thinking 后链是否完整、不成对时报错、不覆盖已有文件、自检能拦住坏序列。
- 本机最近 34 个真实会话，每个跑 dialogue、`--from`、full 三种 dry-run，102 次全部正常退出（只统计、不写文件）。
- 拿一份 4 轮的旧会话真切：full 模式切掉 2 轮、捞回 1 条挂在主线外的并行结果、剥掉 2 块 thinking，产物 14 行，源文件 SHA-256 前后不变。`claude -p --resume` 接上后问「前面调用过的工具都叫什么」，答对了工具名、次数、各自的参数和返回结果。
- 同一份会话 `--all` dialogue（这次没有切，只瘦身）：产物 6 行。接上后问每条人类消息的发送时间和内容，四条全对；它还主动说明前面提到的工具调用在这段对话里看不到，没法核实。这正是 dialogue 该有的样子：话都在，工具被剥掉了，它自己也知道。

我们家 runtime（完整版）：从 2026-09 起日常在用。今天写这份教程的窗口预览了一次：dialogue 模式，18.3 万 token 的窗口，剥掉 47 次工具调用、42 块 thinking，保留段约六千 token。

⇒ 现在能说的是：**在上面这些范围里可用。**长会话、切掉很多轮、压缩过的会话、其他版本和其他平台，还没有真样本覆盖。拿正式窗口跑之前，先整份备份，先用 `--list-turns` / `--dry-run` 把切点看一眼。

附录：slim.py

代码就是仓库里（或随 PDF 一起发的）`slim.py` 文件，直接用那个文件。下面的全文只供阅读；如果你手上只有这份 PDF，复制后先跑一次 `python3 -m py_compile slim.py`，报错就是缩进被排版弄坏了。

```
#!/usr/bin/env python3
"""
slim.py: 给 Claude Code 的会话做一次 slim（第三版）。

从一份旧会话文件（~/.claude/projects/<项目目录>/<会话id>.jsonl）里，
挑一个时间点，把那之前的对话整段拿掉，之后的保留下来，
写成一份新的会话文件，然后用 `claude --resume <新id>` 接着聊。

两种保留方式（--history）：
  dialogue（默认）：只带对话。人说的话、AI 说的话、语音工具（成对）、--keep-tool 指定的工具（成对）。
```

```
                      不做摘要，不改写任何一句话；只加三处标记：压缩摘要前的说明、图片占位、发送时间。
  full:               从切点那一轮起，主线上的行原样带过去（工具调用和结果、图片、附件都在），
                      只改四处：首行 parentUuid 置空并按顺序重新串链、换新 sessionId、删 message.usage、
                      剥掉 thinking。活干到一半、还要用刚才的工具结果时用它。只能配 --from。

旧文件只读，不改不删。新文件排他创建，已存在就报错，绝不覆盖。只用 Python 3.9+ 标准库。

安全提醒：不要让 Claude 用 cat / Read 直接读会话 jsonl。里面逐条存着 thinking 字段，
把它读进上下文可能触发平台拦截（[reasoning_extraction]），整轮被拒。要看有哪些轮次，就用 --list-turns。
这个脚本只在内存里处理 thinking，永远不打印 thinking 的内容。

用法：
  python3 slim.py 旧会话.jsonl --list-turns --tz Asia/Shanghai     # 先看每一轮的时间和开头
  python3 slim.py 旧会话.jsonl --from 2026-09-30T15:40:00+08:00 --dry-run
  python3 slim.py 旧会话.jsonl --from 2026-09-30T15:40:00+08:00 --tz Asia/Shanghai
  python3 slim.py 旧会话.jsonl --from 2026-09-30T15:40:00+08:00 --history full
  python3 slim.py 旧会话.jsonl --all                                # 不切，全部轮次只做瘦身
"""

import argparse
import copy
import json
import os
import re
import sys
import time
import uuid
from datetime import datetime, timezone

try:
    from zoneinfo import ZoneInfo
except ImportError:  # Python < 3.9
    ZoneInfo = None

CHAIN_TYPES = {"user", "assistant", "attachment", "system"}
THINKING_TYPES = {"thinking", "redacted_thinking"}
# Messages API 对 tool_use id 的约束
TOOL_ID_RE = re.compile(r"^[a-zA-Z0-9_-]+$")
# 语音类工具：电话里她说的话只存在于 listen 的返回里，念出口的话只存在于 speak 的输入里，
# 剥掉就两边都没了。所以默认成对保留，--no-voice 关掉。
VOICE_TOOLS = ("mcp__tts__speak", "mcp__voice__speak", "mcp__voice__listen",
               "mcp__voice__converse", "mcp__voice__hangup")


class SlimError(Exception):
    """能预见的失败：给人看的中文说明，不写文件。"""


# ---------- 读 ----------

def load_rows(path):
    rows = []
    with open(path, "r", encoding="utf-8") as f:  # 只读
        for line in f:
            if not line.strip():
                continue
            try:
                row = json.loads(line)
            except json.JSONDecodeError:
                continue  # 写了一半的行，跳过
            if isinstance(row, dict):
                rows.append(row)
    return rows


def active_chain(rows):
    """CLI 恢复时会走的那条主线：从文件里最后写入的一行，沿 parentUuid 往回走。

    rewind、重试留下的废弃分支还在文件里，但最后写入的那一行一定在主线上。
    """
    by_uuid, leaf = {}, None
    for row in rows:
```

```
        u = row.get("uuid")
        if not u or row.get("isSidechain") is True or row.get("type") not in CHAIN_TYPES:
            continue
        by_uuid.setdefault(u, row)
        leaf = row
    chain, seen, row = [], set(), leaf
    while row is not None and row["uuid"] not in seen:
        seen.add(row["uuid"])
        chain.append(row)
        parent = row.get("parentUuid")
        row = by_uuid.get(parent) if parent else None
    chain.reverse()
    return chain


def blocks(row):
    content = (row.get("message") or {}).get("content")
    return [b for b in content if isinstance(b, dict)] if isinstance(content, list) else []


def use_ids(row):
    if row.get("type") != "assistant":
        return []
    return [b.get("id") for b in blocks(row) if b.get("type") == "tool_use"]


def result_ids(row):
    if row.get("type") != "user":
        return []
    return [b.get("tool_use_id") for b in blocks(row) if b.get("type") == "tool_result"]


def sibling_results(rows, chain):
    """并行工具调用的结果，有一部分不在主线上。

    Claude Code 记并行调用时，每个结果行挂在自己那条调用行下面，
    从最后一行往回走只会经过最后一个结果，前面几个结果在旁支上（CLI 恢复时自己会捞回来）。
    这里同样捞回来：tool_use_id → 那条结果行（不在主线、不是子 agent）。
    """
    on_chain = {r.get("uuid") for r in chain}
    found = {}
    for row in rows:
        if row.get("isSidechain") is True or row.get("uuid") in on_chain:
            continue
        for rid in result_ids(row):
            if rid:
                found.setdefault(rid, row)
    return found


def is_prompt(row):
    """一轮的开头：真正由人输入的那条消息（不是工具结果、系统提醒、压缩摘要）。"""
    if row.get("type") != "user" or row.get("isMeta") or row.get("isCompactSummary"):
        return False
    content = (row.get("message") or {}).get("content")
    if isinstance(content, str):
        return bool(content.strip())
    types = [b.get("type") for b in blocks(row)]
    return "tool_result" not in types and any(t in ("text", "image") for t in types)


def parse_time(value):
    if not value:
        return None
    try:
        t = datetime.fromisoformat(str(value).replace("Z", "+00:00"))
    except ValueError:
        return None
    return t if t.tzinfo else None  # 没有时区的时间戳不可信，当作缺失


def split_turns(chain):
```

```
    starts = [i for i, row in enumerate(chain) if is_prompt(row)]
    turns = []
    for n, start in enumerate(starts):
        begin = 0 if n == 0 else start  # 第一轮之前的东西（比如压缩摘要、上次 slim 的头）算进第一轮
        end = starts[n + 1] if n + 1 < len(starts) else len(chain)
        times = [t for t in (parse_time(r.get("timestamp")) for r in chain[begin:end]) if t]
        turns.append({"begin": begin, "start": start, "end": end,
                      "started": parse_time(chain[start].get("timestamp")),
                      "ended": max(times) if times else None})
    return turns


def prompt_text(row):
    """人说的话的文字。只取 text，图片换占位；永远不碰 thinking。"""
    content = (row.get("message") or {}).get("content")
    if isinstance(content, str):
        return content
    parts = []
    for b in blocks(row):
        if b.get("type") == "text":
            parts.append(b.get("text", ""))
        elif b.get("type") == "image":
            parts.append("[图片，slim 时省略]")
    return "\n".join(p for p in parts if p)


# ---------- 时区 ----------

def local_zone_name():
    """本机时区的名字，尽量拿到 Asia/Shanghai 这种形式。"""
    tz_env = os.environ.get("TZ", "").lstrip(":")
    if tz_env and "/" in tz_env:
        return tz_env
    try:
        target = os.path.realpath("/etc/localtime")
        if "zoneinfo/" in target:
            return target.split("zoneinfo/", 1)[1]
    except OSError:
        pass
    try:
        with open("/etc/timezone", encoding="utf-8") as f:  # 部分 Linux
            name = f.read().strip()
            if name:
                return name
    except OSError:
        pass
    return None


def resolve_tz(name):
    """返回 (tzinfo 或 None, 给人看的说明)。None 表示用本机时区（astimezone()）。"""
    if name:
        if ZoneInfo is None:
            raise SlimError("这个 Python 没有 zoneinfo（需要 3.9+），不能用 --tz。")
        try:
            return ZoneInfo(name), None
        except Exception:
            raise SlimError(f"认不出时区 {name}。写成 Asia/Shanghai 这种形式；"
                            "Windows 上可能要先 pip install tzdata。")
    zone = local_zone_name()
    offset = datetime.now().astimezone().strftime("%z")
    offset = offset[:3] + ":" + offset[3:] if offset else "?"
    if zone and ZoneInfo is not None:
        try:
            return ZoneInfo(zone), f"使用本机时区 {zone}（现在是 UTC{offset}）；要换就加 --tz"
        except Exception:
            pass
    abbr = time.tzname[0] if time.tzname else "?"
    return None, f"使用本机时区 {abbr}（现在是 UTC{offset}）；要换就加 --tz"


def to_local(ts, tz):
```

```
    t = parse_time(ts)
    if not t:
        return None
    return t.astimezone(tz) if tz else t.astimezone()


def short_label(ts, tz):
    t = to_local(ts, tz)
    return t.strftime("%Y-%m-%d %H:%M") if t else None


def iso_label(ts, tz):
    t = to_local(ts, tz)
    return t.isoformat(timespec="seconds") if t else None


# ---------- dialogue: 投影成对话 ----------

def project_dialogue(kept, keep_tools, extra_results, add_time, tz, stats):
    """把保留段投影成对话事件：人说的话、AI 说的话、要保留的工具（调用和结果一起）。

    工具以「一对」为单位出事件：遇到 tool_use 时把它的结果一起带上，
    结果行后面再遇到就跳过。并行调用因此也是 调用1→结果1→调用2→结果2。
    """
    results = {}  # tool_use_id → (结果块, toolUseResult, 时间戳)
    for row in kept:
        for b in blocks(row):
            if row.get("type") == "user" and b.get("type") == "tool_result":
                results.setdefault(b.get("tool_use_id"),
                                   (b, row.get("toolUseResult"), row.get("timestamp")))
    for rid, row in extra_results.items():
        for b in blocks(row):
            if b.get("type") == "tool_result" and b.get("tool_use_id") == rid:
                results.setdefault(rid, (b, row.get("toolUseResult"), row.get("timestamp")))

    events = []  # (kind, payload, timestamp)
    for row in kept:
        ts = row.get("timestamp")
        kind = row.get("type")
        if kind == "user":
            if row.get("isCompactSummary"):
                content = (row.get("message") or {}).get("content")
                text = content if isinstance(content, str) else prompt_text(row)
                if text.strip():
                    note = "[这之前的对话被 Claude Code 自动压缩过，下面是压缩摘要]\n"
                    events.append(("user", note + text, ts))
            elif is_prompt(row):
                text = prompt_text(row)
                if text.startswith(("<command-", "<local-command-")):
                    continue  # 斜杠命令和它的输出，不是对话
                if add_time:
                    label = iso_label(ts, tz)
                    if label:
                        text = f"[消息发送时间：{label}]\n{text}"
                    else:
                        stats["no_time_prompts"] += 1
                events.append(("user", text, ts))
            # 工具结果行：结果已经跟着它的调用出过了，这里不再输出
        elif kind == "assistant":
            for b in blocks(row):
                t = b.get("type")
                if t == "text" and b.get("text", "").strip():
                    events.append(("text", b["text"], ts))
                elif t == "tool_use":
                    hit = results.get(b.get("id"))
                    if b.get("name") in keep_tools and hit is not None:
                        events.append(("tool_pair", {"use": b, "result": hit}, ts))
                    # 其他工具、没有结果的调用：丢掉
                # thinking、图片之外的其他块：丢掉
    return events
```

```
def build_dialogue_rows(events, session_id, cwd, model, stats):
    rows, parent, pending = [], None, []
    used_ids = set()
    known = [ts for _, _, ts in events if parse_time(ts)]
    fallback = known[0] if known else datetime.now(timezone.utc).isoformat()

    def fix_ts(ts):
        nonlocal fallback
        if parse_time(ts):
            fallback = ts
            return ts
        stats["no_time_rows"] += 1  # 缺时间戳：借用前一行的时间，并计数警告
        return fallback

    def push(kind, message, ts, extra=None):
        nonlocal parent
        u = str(uuid.uuid4())
        row = {"parentUuid": parent, "isSidechain": False, "type": kind, "uuid": u,
               "timestamp": fix_ts(ts), "sessionId": session_id, "cwd": cwd, "message": message}
        if extra:
            row.update(extra)
        rows.append(row)
        parent = u

    def flush(ts):
        nonlocal pending
        if pending:
            message = {"id": "msg_" + uuid.uuid4().hex, "type": "message",
                       "role": "assistant", "model": model, "content": pending}
            push("assistant", message, ts)
            pending = []

    def tool_id(raw):
        tid = str(raw or "")
        if not TOOL_ID_RE.match(tid) or tid in used_ids:
            tid = "toolu_vslim_" + uuid.uuid4().hex
            stats["renamed_tool_ids"] += 1
        used_ids.add(tid)
        return tid

    last_ts = None
    for kind, payload, ts in events:
        last_ts = ts
        if kind == "user":
            flush(ts)
            push("user", {"role": "user", "content": payload}, ts)
        elif kind == "text":
            pending.append({"type": "text", "text": payload})
        elif kind == "tool_pair":
            use = payload["use"]
            block, tool_use_result, result_ts = payload["result"]
            tid = tool_id(use.get("id"))
            pending.append({"type": "tool_use", "id": tid, "name": use.get("name"),
                            "input": use.get("input") or {}})
            flush(ts)  # 调用结束这条 assistant 消息，下一行紧跟它的结果
            result = {"type": "tool_result", "tool_use_id": tid,
                      "content": block.get("content", "")}
            if block.get("is_error"):
                result["is_error"] = True
            extra = {"toolUseResult": tool_use_result} if tool_use_result is not None else None
            push("user", {"role": "user", "content": [result]}, result_ts or ts, extra)
    flush(last_ts)
    return rows


# ---------- full：原行带过去 ----------

def build_full_rows(kept, extra_results, session_id, cwd_override, stats):
    """保留段原行深拷贝。只改：剥 thinking、首行 parentUuid=null 并重新串链、
    换 sessionId、删 message.usage（以及给了 --cwd 时的 cwd）。"""
    rows = [copy.deepcopy(r) for r in kept]
    on_chain = {r.get("uuid") for r in rows}
```

```
        kept_uses = {i for r in rows for i in use_ids(r)}
        kept_answered = {i for r in rows for i in result_ids(r)}
        extras = []
        for rid, row in extra_results.items():
            # 只捞保留段里有调用、却还没有结果的那几条
            if rid not in kept_uses or rid in kept_answered:
                continue
            if row.get("uuid") not in on_chain:
                on_chain.add(row.get("uuid"))
                extras.append(copy.deepcopy(row))
        stats["recovered_results"] = len(extras)
        rows.extend(extras)

        # 1. 剥 thinking；剥完空了的 assistant 行整行删掉
        cleaned = []
        for row in rows:
            content = (row.get("message") or {}).get("content")
            if row.get("type") == "assistant" and isinstance(content, list):
                keep = [b for b in content if not (isinstance(b, dict) and b.get("type") in THINKING_TYPES)]
                stripped = len(content) - len(keep)
                if stripped:
                    stats["thinking"] += stripped
                    row["message"]["content"] = keep
                    if not keep:
                        stats["dropped_rows"] += 1
                        continue
            cleaned.append(row)
        rows = cleaned

        # 2. 配对检查。最后一轮里还没返回的调用（比如正在跑 slim 的这一次）去掉，其余不成对就拒绝
        uses = {i for r in rows for i in use_ids(r)}
        answered = {i for r in rows for i in result_ids(r)}
        orphans = [i for i in answered if i not in uses]
        unanswered = [i for i in uses if i not in answered]
        if unanswered:
            last_prompt = max((n for n, r in enumerate(rows) if is_prompt(r)), default=-1)
            final_ids = set()
            last_mid = None
            for n in range(len(rows) - 1, -1, -1):  # 最后一条 assistant 消息（同一个 message.id）
                if rows[n].get("type") == "assistant":
                    last_mid = (rows[n].get("message") or {}).get("id")
                    break
            for n, r in enumerate(rows):
                if n > last_prompt and r.get("type") == "assistant" and \
                        (r.get("message") or {}).get("id") == last_mid:
                    final_ids.update(use_ids(r))
            in_flight = [i for i in unanswered if i in final_ids]
            unanswered = [i for i in unanswered if i not in final_ids]
            if in_flight and not unanswered and not orphans:
                stats["dropped_tools"] += len(in_flight)
                drop = set(in_flight)
                kept_rows = []
                for r in rows:
                    if r.get("type") == "assistant" and drop & set(use_ids(r)):
                        r["message"]["content"] = [b for b in blocks(r) if not (
                            b.get("type") == "tool_use" and b.get("id") in drop)]
                        if not r["message"]["content"]:
                            stats["dropped_rows"] += 1
                            continue
                    kept_rows.append(r)
                rows = kept_rows
        if unanswered or orphans:
            raise SlimError(f"保留段里的工具调用不成对：{len(unanswered)} 个调用没有结果，"
                            f"{len(orphans)} 个结果找不到调用。full 模式不能只带一半（API 会拒绝）。"
                            "把切点往前或往后挪一轮，或者改用 --history dialogue。")

        # 3. 每个调用行后面紧跟它的结果行（并行调用：调用1→结果1→调用2→结果2，CLI 自己也这样记）
        by_result = {}
        for r in rows:
            for rid in result_ids(r):
                by_result.setdefault(rid, r)
        result_rows = {id(r) for r in by_result.values()}
```

```
    ordered, placed = [], set()
    for r in rows:
        if id(r) in result_rows:
            continue
        ordered.append(r)
        for uid in use_ids(r):
            rr = by_result.get(uid)
            if rr is not None and id(rr) not in placed:
                placed.add(id(rr))
                ordered.append(rr)
    rows = ordered

    # 4. 重新串链、换 sessionId、删 usage
    parent = None
    for r in rows:
        r["parentUuid"] = parent
        r["sessionId"] = session_id
        if cwd_override:
            r["cwd"] = cwd_override
        if isinstance(r.get("message"), dict):
            r["message"].pop("usage", None)
        if r.get("type") in ("user", "assistant") and not parse_time(r.get("timestamp")):
            stats["no_time_rows"] += 1
        parent = r.get("uuid")
    return rows


# ---------- 自检 ----------

def validate(rows, session_id):
    """写文件之前的自检。返回问题列表（只含行号和 id，不含任何内容）；空列表才写。"""
    problems = []
    if not rows:
        return ["新会话一行都没有"]
    seen = set()
    for n, r in enumerate(rows):
        u = r.get("uuid")
        if not u:
            problems.append(f"第 {n + 1} 行没有 uuid")
        elif u in seen:
            problems.append(f"第 {n + 1} 行 uuid 重复：{u}")
        seen.add(u)
        want = None if n == 0 else rows[n - 1].get("uuid")
        if r.get("parentUuid") != want:
            problems.append(f"第 {n + 1} 行 parentUuid 没有指向上一行" if n else
                            "第 1 行 parentUuid 不是 null")
        if r.get("sessionId") != session_id:
            problems.append(f"第 {n + 1} 行 sessionId 不是新 id")
        message = r.get("message")
        if isinstance(message, dict) and "usage" in message:
            problems.append(f"第 {n + 1} 行还带着 message.usage")
        for b in blocks(r):
            if b.get("type") in THINKING_TYPES:
                problems.append(f"第 {n + 1} 行还有 {b.get('type')} 块")

    tool_seen = set()
    for n, r in enumerate(rows):
        ids = use_ids(r)
        for i in ids:
            if not isinstance(i, str) or not TOOL_ID_RE.match(i):
                problems.append(f"第 {n + 1} 行 tool_use.id 不合法：{i!r}")
            elif i in tool_seen:
                problems.append(f"第 {n + 1} 行 tool_use.id 重复：{i}")
            tool_seen.add(i)
        if ids:
            # 下一行（连续几行结果行）必须含它的 tool_result
            got, m = set(), n + 1
            while m < len(rows) and result_ids(rows[m]):
                got.update(result_ids(rows[m]))
                m += 1
            for i in ids:
                if i not in got:
```

```
                    problems.append(f"第 {n + 1} 行的 tool_use {i} 下一行不是它的 tool_result")
        rids = result_ids(r)
        if rids:
            # 往前跨过连续的结果行，第一条非结果行必须是含对应 tool_use 的那行
            m = n - 1
            while m ⩾ 0 and result_ids(rows[m]):
                m -= 1
            before = set(use_ids(rows[m])) if m ⩾ 0 else set()
            for i in rids:
                if i not in before:
                    problems.append(f"第 {n + 1} 行的 tool_result {i} 前一行没有对应的 tool_use")
    return problems


# ---------- 写 ----------

def project_dir_for(cwd):
    slug = "".join(c if (c.isalnum() and c.isascii()) or c in ".-" else "-" for c in cwd)
    return os.path.join(os.path.expanduser("~"), ".claude", "projects", slug)


def serialize(rows):
    return "".join(json.dumps(r, ensure_ascii=False) + "\n" for r in rows).encode("utf-8")


def write_session(path, data):
    """排他创建：已存在就抛 FileExistsError，绝不覆盖。写完 fsync 文件和目录。"""
    fd = os.open(path, os.O_WRONLY | os.O_CREAT | os.O_EXCL, 0o600)
    try:
        view = memoryview(data)
        while view:
            n = os.write(fd, view)
            view = view[n:]
        os.fsync(fd)
    finally:
        os.close(fd)
    try:
        dfd = os.open(os.path.dirname(path) or ".", os.O_RDONLY)
        try:
            os.fsync(dfd)
        finally:
            os.close(dfd)
    except OSError:
        pass  # 有的文件系统不支持对目录 fsync，文件本身已经落盘


# ---------- 主流程 ----------

def parse_args(argv=None):
    ap = argparse.ArgumentParser(
        description="给 Claude Code 会话做一次 slim：切掉某个时间点之前的轮次，保留之后的原话")
    ap.add_argument("source", help="旧会话文件 .jsonl（只读）")
    ap.add_argument("--from", dest="retain_from",
                    help="保留这个时间点之后结束的完整轮次，必须带时区，如 2026-09-30T15:40:00+08:00")
    ap.add_argument("--all", action="store_true",
                    help="不切，全部轮次都保留，只做 dialogue 瘦身（与 --from 二选一）")
    ap.add_argument("--history", choices=("dialogue", "full"), default="dialogue",
                    help="dialogue（默认）只带对话；full 把保留段原行带过去（只能配 --from）")
    ap.add_argument("--keep-tool", action="append", default=[],
                    help="dialogue 模式下额外成对保留的工具名，可以写多次")
    ap.add_argument("--no-voice", action="store_true",
                    help="不默认保留语音工具（" + "、".join(VOICE_TOOLS) + "）")
    ap.add_argument("--no-time", action="store_true", help="不在人说的话前面加发送时间")
    ap.add_argument("--tz", help="显示和发送时间用的时区，例如 Asia/Shanghai；默认用本机时区")
    ap.add_argument("--cwd", help="新会话所属的项目目录；默认和旧会话相同")
    ap.add_argument("--list-turns", action="store_true",
                    help="列出每一轮的时间和人说的话的开头，不写文件")
    ap.add_argument("--dry-run", action="store_true", help="只统计，不写文件")
    return ap.parse_args(argv)


def run(args):
```

```
    tz, tz_note = resolve_tz(args.tz)
    if tz_note:
        print(tz_note)

    rows = load_rows(args.source)
    chain = active_chain(rows)
    turns = split_turns(chain)
    if not turns:
        raise SlimError("这份文件里找不到对话轮次。")

    if args.list_turns:
        for n, t in enumerate(turns):
            head = prompt_text(chain[t["start"]]).replace("\n", " ")[:50]
            label = short_label(chain[t["start"]].get("timestamp"), tz) or "?"
            print(f"{n:4d}  {label:16s}  {head}")
        return 0

    if args.all and args.retain_from:
        raise SlimError("--all 和 --from 只能二选一：--all 是全部保留，--from 是从某个时间点切。")
    if args.all and args.history == "full":
        raise SlimError("--all 不能配 --history full：那等于把要离开的整个 context 原样搬过去，"
                        "什么都没省。全部保留就用 --all（dialogue）；要带工具结果就用 --from 切掉前面一段。")
    if not args.all and not args.retain_from:
        raise SlimError("需要 --from（带时区的时间点）或者 --all。先用 --list-turns 看看每一轮的时间。")

    if args.all:
        first = 0
    else:
        cut_at = parse_time(args.retain_from)
        if not cut_at:
            raise SlimError("--from 必须是带时区的时间，例如 2026-09-30T15:40:00+08:00")
        if cut_at > datetime.now(timezone.utc):
            raise SlimError("--from 在未来。")
        first = next((i for i, t in enumerate(turns) if t["ended"] and t["ended"] >= cut_at), None)
        if first is None:
            raise SlimError("这个时间点之后没有完整的轮次。")
    kept = chain[turns[first]["begin"]:]
    extra = sibling_results(rows, chain)

    models = [r["message"].get("model") for r in chain
              if r.get("type") == "assistant" and isinstance(r.get("message"), dict)]
    models = [m for m in models if m and m != "<synthetic>"]
    model = models[-1] if models else "claude"
    cwd = args.cwd or next((r.get("cwd") for r in reversed(chain) if r.get("cwd")), None)
    if not cwd:
        raise SlimError("旧会话里没有 cwd，请用 --cwd 指定项目目录。")
    if args.cwd and not os.path.isabs(args.cwd):
        raise SlimError("--cwd 必须是绝对路径。")

    stats = {"no_time_prompts": 0, "no_time_rows": 0, "renamed_tool_ids": 0, "thinking": 0,
             "dropped_rows": 0, "dropped_tools": 0, "recovered_results": 0}
    kept_uses = sum(1 for r in kept for b in blocks(r) if b.get("type") == "tool_use")
    kept_thinking = sum(1 for r in kept for b in blocks(r) if b.get("type") in THINKING_TYPES)
    kept_images = sum(1 for r in kept for b in blocks(r) if b.get("type") == "image")

    new_id = str(uuid.uuid4())
    if args.history == "full":
        if args.keep_tool or args.no_voice:
            print("提示：full 模式保留全部工具，--keep-tool / --no-voice 不起作用。")
        out_rows = build_full_rows(kept, extra, new_id, args.cwd, stats)
    else:
        keep_tools = set(args.keep_tool)
        if not args.no_voice:
            keep_tools.update(VOICE_TOOLS)
        events = project_dialogue(kept, keep_tools, extra, not args.no_time, tz, stats)
        out_rows = build_dialogue_rows(events, new_id, cwd, model, stats)
        stats["dropped_tools"] = kept_uses - sum(
            1 for r in out_rows for b in blocks(r) if b.get("type") == "tool_use")
        stats["thinking"] = kept_thinking

    problems = validate(out_rows, new_id)
    data = serialize(out_rows)
```

```
    # ---- 统计 ----
    first_turn, last_turn = turns[first], turns[-1]
    mode = "全部保留 (--all) " if args.all else f"从 --from {args.retain_from} 切"
    print(f"模式: {args.history}, {mode}")
    print(f"总轮次 {len(turns)}, 切掉 {first} 轮, 保留第 {first} 轮起的 {len(turns) - first} 轮")
    print(f"保留段: 第一轮开始于 {short_label(chain[first_turn['start']].get('timestamp'), tz) or '?'}, "
          f"最后一轮结束于 {short_label(last_turn['ended'].isoformat() if last_turn['ended'] else None, tz) or '?'}")
    if args.history == "full":
        print(f"保留段里: 工具调用 {kept_uses - stats['dropped_tools']} 次带过去"
              f" (丢掉还没返回的 {stats['dropped_tools']} 次, 捞回并行调用的旁支结果 "
              f"{stats['recovered_results']} 条), 剥掉 thinking {stats['thinking']} 块"
              f" (因此整行删掉 {stats['dropped_rows']} 行), 图片 {kept_images} 张原样带过去")
    else:
        print(f"保留段里: 丢掉工具调用 {stats['dropped_tools']} 次, thinking {stats['thinking']} 块, "
              f"图片 {kept_images} 张 (只留占位) ")
    print(f"新会话 {len(out_rows)} 行, 产物 {len(data)} 字节, "
          f"粗估约 {len(data) // 3} token (字节÷3 的粗估, 只看量级) ")
    if stats["renamed_tool_ids"]:
        print(f"注意: {stats['renamed_tool_ids']} 个 tool_use id 不合法或重复, 已换成新 id")
    missing = stats["no_time_prompts"] + stats["no_time_rows"]
    if missing:
        print(f"警告: 保留的行里有 {missing} 处缺时间戳"
              f" ({stats['no_time_prompts']} 条人说的话没加上发送时间, "
              f"{stats['no_time_rows']} 行借用了前一行的时间或保持原样) ")

    if problems:
        print("自检没通过, 不写文件: ", file=sys.stderr)
        for p in problems[:20]:
            print("  - " + p, file=sys.stderr)
        if len(problems) > 20:
            print(f"  ……还有 {len(problems) - 20} 条", file=sys.stderr)
        return 2
    print("自检通过: 工具调用都紧跟结果、uuid 唯一、单链、无 usage、无 thinking")

    if args.dry_run:
        print("dry-run: 没有写文件。")
        return 0

    # 默认写在旧文件旁边: 同一个项目目录, claude --resume 才找得到
    out_dir = project_dir_for(cwd) if args.cwd else os.path.dirname(os.path.abspath(args.source))
    os.makedirs(out_dir, mode=0o700, exist_ok=True)
    out_path = os.path.join(out_dir, new_id + ".jsonl")
    if os.path.abspath(out_path) == os.path.abspath(args.source):
        raise SlimError("新文件路径和旧文件相同, 停下。")
    try:
        write_session(out_path, data)
    except FileExistsError:
        raise SlimError(f"{out_path} 已经存在, 不覆盖。再跑一次会换一个新 id。")
    print(f"已写入 {out_path}")
    print(f"新 session id: {new_id}")
    print(f"接着聊: cd {cwd} && claude --resume {new_id}")
    print("有自己的 bridge 管 session_id 的, 把记着的 id 换成这个即可")
    return 0


def main(argv=None):
    args = parse_args(argv)
    try:
        return run(args)
    except SlimError as e:
        print(str(e), file=sys.stderr)
        return 1


if __name__ == "__main__":
    sys.exit(main())
```